

UNIVERSITÉ DE PAU ET DES PAYS DE L'ADOUR



Master 2 Recherche Économie Appliquée
Projet Séries Temporelles et Machine Learning

L'intelligence artificielle comme moteur de bulles spéculatives

Réalisé par :

Boubou DIANKA

Sous la direction de :

M. Jamal BOUOYOUR

M. Hamou ELOTMANY

Année universitaire : 2025–2026

Table des matières

1	Introduction	3
2	État de l'art : bulles spéculatives liées à l'intelligence artificielle	4
2.1	Détection économétrique des bulles spéculatives	4
2.2	Analyse multi-échelles et dynamiques de marché	4
2.3	Apports récents du Machine Learning	4
3	Stratégie Empiriques et Data	5
3.1	Donnée	5
3.1.1	Source	5
3.1.2	Analyse préliminaire	5
3.2	Modélisation GARCH	13
3.2.1	Résultats	13
3.2.2	Discussion	18
4	Empirical Mode Decomposition	19
4.1	Prétraitement des séries	19
4.2	Résultats	19
4.2.1	La hiérarchie fréquentielle	19
4.2.2	La hiérarchie énergétique	23
4.2.3	Régimes temporels : dominance des dynamiques de court terme	25
4.2.4	La Robustesse de la décomposition	26
4.2.5	Avant et après 2022 : réorganisation des dynamiques	28
4.3	Discussion	29
5	Analyse ondulatoire des mouvements de prix	30
5.1	Analyse préliminaire	31
5.2	Résultat	33
5.2.1	Décomposition ondelette des log-prix	33
5.2.2	Rendements et distribution énergétique	37
5.2.3	Orthogonalité des composantes ondelettes	39
5.2.4	Comparaison des rendements avant et après 2022	41
5.3	Discussion	44
6	Détection des bulles spéculatives	46
6.1	Méthodologie : tests GSADF et BSADF	46
6.2	Résultats empiriques	46
6.3	Discussion	48
7	Machine learning	49
7.1	Prétraitement des données	49
7.2	Résultats	50
7.3	Discussion	55
8	Conclusion	56

9 Références	57
10 Annexes	58

1 Introduction

Depuis 2020, l'intelligence artificielle a connu une expansion rapide transformant profondément les géants marchés financiers technologiques américains. Les prix de ses actions deviennent plus volatiles, des volumes inhabituelles, accompagnés d'un regain d'attention médiatique et informationnelle. Ces dynamiques soulèvent aujourd'hui une question d'autant plus cruciale que des bulles spéculatives ont été historiquement liées à des risques systématiques importants et à des corrections brutales des marchés pour l'analyse économique et financiers : ***en quoi le boom de l'IA reflète-t-il une réévaluation fondamentale des perspectives économiques, correspond-il à des phases de surchauffe spéculatives ?***

Ce projet s'inscrit précisément dans cette logique d'idée en étudiant la dynamique des rendements des actifs technologiques et formule en ces termes la problématique suivante : **les marchés technologies ont-ils connus des phases de bulles spéculatives associées au narratifs de l'IA, et comment se manifestent-elles ces phases aux différentes échelles temporelles dans la volatilité, les volumes et les rendements ?** Pour répondre à cette question, l'étude mobilise à la fois des méthodes économétriques de détection de bulles, les outils multi-échelles et les approches de machine learning appliquées aux rendements de **Microsoft, Tesla** et du **Nasdaq Composite** sur la période **2021-2026**.

La littérature financière propose plusieurs cadres méthodologiques d'analyses des bulles, notamment les tests récursifs **GSADF/BSADF** développés par **Phillips, Shi et Yu (2015)** permettant de diagnostiquer et de dater les épisodes explosifs sur les marchés financiers. Basele, **Phillips et Shi (2025)** et **Maghyereh et Awartani (2025)**, à travers ces outils, ils ont montré des bulles synchronisées sur certaines actions emblématiques. Par ailleurs, Atsiwo (2025), propose une approche différente, combinant détection économétrique et machine learning et montrent le rôle important des variables macro-financières par rapport au sentiment informationnel. Toutefois, ces travaux n'intègrent pas pleinement une analyse multi-échelle des dynamiques de marché, restent souvent centrés soit sur la détection soit sur la prédiction.

Ce projet ajoute une valeur ajoutée à la littérature en combinant d'abord la détection des bulles par les tests **GSADF/BSADF** avec analyse multi-échelle fondée sur la décomposition **EMD** et les ondelettes, permettant de distinguer les régimes de **court, moyen et long de la volatilité**. Ensuite, il offre une lecture intégrée du rôle du narratif de l'IA en mettant en relation les phases spéculatives avec des indicateurs macro-financières et informationnels (**VIX, EPU, Google Trends, Wikipedia**). Enfin, il souligne les limites prédictives pour hiérarchiser les facteurs de marché en évaluant la capacité des modèles de **machine learning** à expliquer les rendements.

Le projet commence par une analyse exploratoire et économétrique des rendements et de la volatilité. Il présente ensuite la section consacrée à l'analyse multi-échelle par **EMD** et la hiérarchie énergétique des dynamiques de marché (les ondelettes). Les dernières sections présentent la détection des bulles et le modèle de machine learning appliqués aux rendements.

2 État de l’art : bulles spéculatives liées à l’intelligence artificielle

2.1 Détection économétrique des bulles spéculatives

La littérature économétrique sur les bulles s’articule principalement autour de la détection des dynamiques explosives de séquences persistantes des rendements anormaux. Les approches fondatrices mobilisent comme base les modèles de bulles rationnelles (**Blanchard et Watson, 1982; Evans, 1991**), où les prix s’éloignent durablement des fondamentaux sous anticipations rationnelles. L’introduction des tests de dépendance de durée apportée par **McQueen et Thorley (1994)** constitue une avancée majeure. En mettant l’accent sur la temporalité des bulles plutôt que sur une simple déviation ponctuelle, il montre que dans un contexte spéculative, la probabilité de fin d’une séquence de rendements positif peut dépendre de sa durée. Parallèlement, se sont imposés aujourd’hui les tests de **SY / GSADF (Phillips, Shi et Yu, 2015)** comme référence centrale pour la détection et le **datestamping** en temps réel des bulles multiples. En raison de leur capacité à identifier les épisodes explosifs récurrents, et ce même en présence de ruptures structurelles, en fait l’outil moderne de la littérature récente. Ils sont très utilisés comme générateurs de labels pour des analyses empiriques et prédictives. Pour finir, **Dettoni et al. (2025)** rendent plus pertinent ce cadre en combinant ces tests avec des modèles à mémoires longue (**intégration fractionnaire**) permettant de distinguer persistance structurelle et comportement explosif et affirment que certaines bulles peuvent être spéculatives, rationnelles et compatibles avec les dynamiques de long terme.

2.2 Analyse multi-échelles et dynamiques de marché

Au-delà de la détection des bulles, la littérature souligne la nécessité d’étudier les marchés financiers comme des systèmes multi-horizons. La volatilité, les volumes et les rendements résultent de l’agrégation des comportements hétérogènes opérant à des différentes échelles temporelles. Dans ce sens, l’**Empirical Mode Decomposition (EMD)** permet de spécifier les composantes de **court, moyen et long terme** sans nécessiter une structure paramétrique. Aujourd’hui, les phases de bulles s’expriment par une hausse des fluctuations du court et non par une transformation immédiate des composantes structurelles. Les IMFs de haute fréquence, intermédiaires et de basse fréquence capturent respectivement les ajustements transactionnelle, de liquidité et les dynamiques persistantes et structurelles (**Basele, Phillips et Shi, 2025 ; Maghyereh et Awartani, 2025**)

2.3 Apports récents du Machine Learning

Pour dépasser les limites des approches purement économétrique en matière de prévisions et de signaux d’alerte précoce, la littérature mobilise les méthodes de **Machine Learning** suivant une logique commune. L’article d’**Atsiwo (2025)**, combine détection PSY/GSADF, extraction de sentiment et modèles d’ensemble (**Random Forest, XGBoost, AdaBoost**) pour montrer que le sentiment apporte une information marginale. Les fondamentaux macroéconomiques (**GDP, CPI, BOP, taux d’intérêt**) constituent les déterminants dominants des épisodes de bulle. Également, d’autres travaux confirment la supériorité de cette approche, mais toutefois, la limite importante de cette littérature réside dans l’agrégation excessive des marchés souvent en indice globale et sans distinction sectorielle, ni prise en compte explicite des dynamiques de marchés spécifiques à certains narratifs de l’intelligence artificielle.

3 Stratégie Empiriques et Data

3.1 Donnée

3.1.1 Source

Table 1: Actifs, variables extraites et sources

Actif	Ticker	Variable extraite	Source
Microsoft	MSFT	Prix ajusté, volume	Yahoo Finance
Tesla	TSLA	Prix ajusté, volume	Yahoo Finance
Nasdaq Composite	IXIC	Prix ajusté, volume	Yahoo Finance
Volatilité marché	VIX	Niveau du VIX	Yahoo Finance
Or	GC=F	Prix spot	Yahoo Finance
Pétrole (WTI)	CL=F	Prix spot	Yahoo Finance
Incertitude politique	USEPUINDXD	Indice EPU	FRED (St. Louis Fed)
Attention investisseurs	–	Recherche “stock market”	Google Trends
Narratif IA	–	Pages vues “Artificial intelligence”	Wikimedia

L’étude repose sur les données journalières couvrant la période allant de **Janvier 2021** à **février 2026**. Les trois actifs financiers représentatifs étudiés sont **Microsoft (MSFT)**, **Tesla (TSLA)** et le **Nasdaq composite (^IXI)**. Les rendements logarithmiques sont calculés par :

$$r_t = \log\left(\frac{P_t}{P_{t-1}}\right),$$

avec P_t prix ajusté de clôture à la date t .

Les variables macrofinancières : la volatilité implicite du marché (**VIX = indice de la peur**), l’Or (GOLD), le pétrole **WTI (OIL)** et Economic Policy Uncertainty (**EPU**) pour les États, sont intégrés pour capturer l’environnement de risque et d’incertitude. A cela, s’ajoute les indicateurs d’attention des investisseurs et de narrations autour des marchés et de L’IA, tels que Google trends, pages vues Wikipedia. La base finale comprend l’ensemble des séries aligné en fréquence journalière, concaténé et nettoyé des valeurs manquantes.

3.1.2 Analyse préliminaire

Cette section présente les propriétés statistiques des séries de prix, de rendements, ainsi que les variables macrofinancières.

Évolution des Prix : La figure 1 présente la dynamique des prix ajusté de Tesla (**TSLA**), Microsoft (**MSFT**) et du **Nasdaq** sur la période 2021 - 2026. Nous observons une tendance à la hausse de long terme pour les trois actifs, entrecoupé de phase de corrections . Cette hausse est plus marquée pendant la période 2022, période qui semble associé à un resserrement monétaire plus rapide et à une hausse de l’incertitude macrofinancières. **Tesla**, présente une forte volatilité, tandis que le Nasdaq reflète

des dynamiques de marché agrégées. Nous observons également la non stationnarité de prix des trois actifs, confirmé par le test **ADF**.

Statistiques descriptives : Les tableaux 4 illustrent une forte dispersion des prix et les autres indicateurs macros financiers. A travers les coefficients de variations, la variabilité relative est plus marquée pour Tesla que pour le Nasdaq et Microsoft. On note également une distribution asymétrique avec un skewness positif, et aussi une distribution leptokurtique très importante pour le **VIX**, l'attention **Google trends**, l'activité **Wikipédia** lié à l'IA et l'indice **EPU**. L'hypothèse de normalité est systématiquement rejetée par le test de normalité de Jarque Bera, illustrant ainsi la présence de queues épaisses et d'épisode extrême. D'ailleurs, c'est qui caractérise les marchés financiers et les phases de tension ou d'euphorie.

Analyse des rendements et dépendance temporelles : Les rendements logarithmiques définissent en moyenne un comportement proche d'un bruit blanc. Globalement, les fonctions d'auto-corrélation (**ACF**) et auto-corrélation partielle (**PACF**) des rendements sont non significatives, c'est qui est d'ailleurs conforme à l'hypothèse d'efficience faible des marchés.

En revanche, leurs carrées révèlent autre choses, il y'a une auto-corrélation qui est persistante au premiers retards, autrement dit une **hétéroscédasticité conditionnelle**. C'est un phénomène de « volatility clustering », elle est observable pour les trois actifs et constitue un fait stylisé central de la finance empirique.

Cette dépendance est principalement de court terme (voir PACF 2), c'est ce qui motive dans la section suivante le recours à des modèles de volatilité conditionnelle de type ARCH/GARCH.

Variable macrofinancières et attentions des investisseurs : Les indicateurs d'attention et de stress (**VIX**, **EPU**, **Google Trends**, **Wikipédia**) présentent des pics importantes après 2022. Ce sont des dynamiques traduisant l'intensification de l'incertitude, le rôle des narratifs technologiques, éléments indispensables dans l'étude des bulles spéculatives contemporaine

En sommes, nous mettons en évidence la non-stationnarité des prix, la stationnarité conditionnelle des rendements, la volatilité persistante et un environnement informationnel et macro-financier profondément modifié après 2022 (voir figures 3 et 4) . C'est la raison pour la quelle nous adoptons dans la suite du travail une approche multi-méthode pour étudier les dynamiques spéculatives et les changements du régime de marché.

Table 2: Statistiques descriptives

	MSFT	TSLA	NASDAQ	VIX
Count	1275.0000	1275.0000	1275.0000	1275.0000
Mean	344.6427	268.2528	15589.4544	19.2916
Std	89.9932	79.4736	3484.6634	5.2659
Min	203.6623	108.1000	10213.2900	11.8600
Max	541.0574	489.8800	23958.4707	52.3300
25%	266.0942	212.0350	13126.5200	15.6050
50%	324.6016	250.2100	14701.9199	17.9900
75%	416.0117	314.9917	17878.5449	21.8950
Variance	8098.7671	6316.0483	12142878.8660	27.7296
CV	0.2611	0.2963	0.2235	0.2730
Skewness	0.3522	0.7471	0.7008	1.2787
Kurtosis	-1.1047	-0.0513	-0.3780	2.4443
JB_pvalue	1.59e-20	1.86e-26	5.21e-25	4.12e-144

Table 3: Statistiques descriptives

	GOLD	OIL	GT_StockMarket	WIKI_AI	EPU
Count	1275.0000	1275.0000	1275.0000	1275.0000	1275.0000
Mean	2313.8324	75.8505	20.0949	21681.0282	179.3950
Std	733.3207	13.0135	9.1535	9084.9123	131.8737
Min	1623.3000	47.6200	12.0000	6475.0000	5.3900
Max	5318.3999	123.7000	100.0000	116843.0000	1026.3800
25%	1814.2500	67.3200	15.0000	15651.5000	92.7050
50%	1960.1000	73.8900	17.0000	20502.0000	135.1900
75%	2632.0499	81.6350	21.0000	27263.0000	222.8550
Variance	537759.2763	169.3500	83.7861	82535632.0761	17390.6831
CV	0.3169	0.1716	0.4555	0.4190	0.7351
Skewness	1.5681	0.9975	3.8544	1.4489	1.9349
Kurtosis	1.7314	1.2686	24.2644	9.3996	4.6888
JB_stat	678.4246	295.1529	34170.7665	5097.3863	1950.1708
JB_pvalue	4.81e-148	8.10e-65	0.00e+00	0.00e+00	0.00e+00

Table 4: Statistiques descriptives

	ADF_stat	p_value	1%	5%	10%	Stationnaire
MSFT	-1.2679	0.6437	-3.4356	-2.8639	-2.5680	Non
TSLA	-1.9429	0.3122	-3.4356	-2.8638	-2.5680	Non
NASDAQ	-0.2252	0.9355	-3.4356	-2.8639	-2.5680	Non




Figure 1: Évolution PRIX AJUSTÉ





Figure 2: AFC et PACF






Figure 3: Évolution EPU, VIX et Google Trend




Figure 4: Évolution Wiki et Cours de l'Or et du Pétrole

3.2 Modélisation GARCH

La modélisation de la volatilité présente une étape centrale dans l'analyse des bulles spéculatives, en ce sens que, la variance conditionnelle inobservée doit être inférée à partir des données. Ainsi, les modèles **GARCH** (Generalize Autoregressive Conditional Heteroskedasticity) développés par Engle (1982), ensuite généralisés en 1986 par **Bollerslev**, constituent le cadre de référence dans la représentation de l'hétéroscédasticité conditionnelle et le phénomène observé de volatility clustering dans les marchés.

Pour cela, on a décomposé les innovations de rendements en un choc standardisé z_t et une volatilité conditionnelle σ_t . La variation conditionnelle quant à elle, évolue dynamiquement en fonction de sa propre inertie et des chocs passés

$$\sigma_t^2 = \omega + \sum_{j=1}^q \alpha_j \varepsilon_{t-j}^2 + \sum_{i=1}^p \beta_i \sigma_{t-i}^2.$$

$$\varepsilon_t = \sigma_t z_t, \quad z_t \sim \mathcal{N}(0, 1),$$

L'impact immédiat des chocs est mesuré par les paramètres ARCH, s'agissant ceux du GARCH, ils mesurent la persistance de la volatilité, l'une des propriétés essentielles dans l'analyse des épisodes de turbulence financière.

Conformément à la littérature, le comportement de la volatilité, très souvent, varie selon les phases de marché en alternant les périodes calmes et épisodes de forte instabilité (**Bouoiyour, 2012**). Celle-ci devient particulièrement pertinente dans le contexte du boom récent de l'intelligence artificielle, marqué par des phases d'euphories spéculatives et de correction rapides, que l'on associe souvent à une intensification des clusters de volatilité et aux épisodes de bulles détectés par les tests GSADF/BSADF.

Les résultats nous mènent à retenir un modèle T-GARCH(1,1) avec une distribution à queues épaisses des rendements, garantissant ainsi l'absence d'auto-corrélation et d'effet ARCH résiduels dans les résidus standardisés. On obtient une mesure parcimonieuse et robuste de la volatilité conditionnelle, mobilisée pour déterminer l'instabilité des actifs et diagnostiquer les liens avec les phases spéculatives associées à l'IA.

3.2.1 Résultats

Les estimations du modèle T-GARCH(1,1) à la loi student pour l'ensemble des actifs sont présentées dans le tableau 5. Ce modèle permet précisément de capturer la volatilité, les asymétries des chocs et les queues épaisses, éléments centraux des périodes spéculatives.

Persistance de la volatilité : Le coefficient β_1 hautement significatif pour l'ensemble des actifs, traduit une forte inertie de la volatilité; c'est la **volatilité clustering**. Les chocs impactant la variance conditionnelle ont des effets durables, phénomène très marqué lors des phases d'euphorie et d'ajustement liées au boom de l'IA. Le paramètre γ_1 se révèle positif et statistiquement significatif pour **MSFT** et le **NASDAQ**, et faiblement significatif pour **TSLA**. On a un effet levier, les chocs négatifs augmentent plus la volatilité que les chocs positifs de même amplitude, c'est un cas d'asymétrie typique des marchés technologiques associés à des révisions brutales d'anticipations. À l'inverse, le coefficient ARCH α_1 nul pour **MSFT** et le **NASDAQ** traduit une réaction secondée aux chocs par rapport à leur propagation asymétrique et persistante via γ_1 et β_1 .

Queues épaisses et chocs extrêmes : Le paramètre ν significatif pour l'ensemble des actifs confirme la présence de queues épaisses, il y a une probabilité d'événement extrême, ce qui est d'ailleurs

cohérente avec les pics de volatilité observés sur la période **2022-2025**, une période où les actifs sont survalorisés.

Validation du modèle : On observe des pics synchronisés avec les épisodes de stress de marché sur les graphiques de volatilité conditionnelle (figure 5), et les ACF des carrés de résidus (figure 7) ne montrent aucune autocorrection résiduelle significative. Les tests de **Ljung-Box** et **LM-ARCH** confirme aussi l'absence d'effet **ARCH**.

Table 5: Estimation du modèle TGARCH(1,1) à loi Student-t

Coefficient	MSFT	TSLA	NASDAQ
mu	0.0895 (1.62e-02)	0.0673 (4.64e-01)	0.0900 (4.89e-03)
omega	0.0240 (2.25e-01)	0.1840 (1.01e-01)	0.0402 (6.41e-03)
alpha[1]	0.0000 (1.00e+00)	0.0280 (5.86e-03)	0.0000 (1.00e+00)
gamma[1]	0.0641 (3.04e-03)	0.0281 (5.61e-02)	0.1599 (1.02e-05)
beta[1]	0.9593 (1.95e-274)	0.9458 (0.00e+00)	0.8937 (0.00e+00)
nu	5.3503 (1.73e-10)	5.4171 (1.22e-11)	9.2976 (6.67e-05)




Figure 5: Volatilité conditionnelle estimée (σ_t)






Figure 6: Résidus standardisés






Figure 7: ACF des carrés des résidus standardisés ($\hat{u}_t^2$)

3.2.2 Discussion

Les résultats montrent une volatilité fortement persistante et asymétriques, présentant des queues épaisses. Les épisodes de tensions de marché semble se manifester à travers les chocs durables et asymétrique de la volatilité conditionnelle et non par les ajustements transitoires. Toutefois, il est important de s'avoir que le modèle T-GARCH(1,1) demeure intrinsèquement paramétrique et limité pour appréhender les dynamiques multi-échelles et les relations non linéaire complexes entre attention, prix et volatilité, et ce malgré sa capacité à modéliser le *volatility clustering*. Nous allons donc utiliser dans les sections suivantes, des nouvelles approches, telles que le recours aux méthode de décomposition fréquentiel (**EMD**, **Ondelettes**), les test de causalité en mémoire longue et les techniques d'apprentissage automatique.

4 Empirical Mode Decomposition

Étudier les bulles spéculatives dans les secteurs technologique et de l'intelligence artificiel nécessite des outils capable de capturer dans les dynamiques non linéaire. Les phases de formation et de correction des bulles, qu'ils soient explosives (Phillips, Shi et Yu, 2015; Basele, Phillips, Shi, 2025) ou rationnelles (Dettoni, Gil, Alana et Bahamondes, 2025) diffèrent selon l'horizon temporelle. Introduite par (Huang, 1998), l' **Empirical Mode Decomposition** (EMD) permet précisément de capturer cette évolution temporelle des prix et des volumes sans imposer de structure paramétrique. Ainsi, la série $\mathbf{x}(t)$ se repartit en une somme de fonction de mode intrinsèque (IMFs) et d'un résidu de base fréquence.

$$x(t) = \sum_{k=1}^K \text{IMFs}_k(t) + r(t),$$

L'objective étant d'examiner l'évolution des prix et des volumes en cours, moyen et long terme **avant et après 2022**, période correspondant à l'intensification du boom de l'IA.

4.1 Prétraitement des séries

On a d'abord exprimé en logarithme les séries de prix et de volume en niveau, cela permet de stabiliser la variance et d'interpréter les fluctuations en termes relatifs. Ensuite, on a appliqué les log différences aux variations, $\Delta \ln(\mathbf{S}_t)$, constituant une mesure naturelle de rendements ou des taux de croissance. C'est la condition nécessaire à l'analyse multi-échelle des marchés financiers. Ce prétraitement permet à l'**EMD** de capturer à la fois le cours, le moyen et le long terme les fluctuations, facilitant ainsi la comparaison **avant et après 2022** des dynamiques des prix et des volumes.

4.2 Résultats

4.2.1 La hiérarchie fréquentielle

La structure fréquentielle (figures 8, 9 et 10) des trois actifs se présente très proche, allant de 8 à 9 IMFs. Le mécanisme d'ajustement de la liquidité dans le temps ne change pas. Les IMFs de rang faible (IMFs 1-2) correspondent aux fluctuations de courte terme liés au bruit de marché. Ceux intermédiaires (IFMs 3-6), illustrent les cycles plus réguliers qui correspondent au ajustements de liquidité à horizons hebdomadaires. Les derniers, ceux de rang élevé (**IMFs** ≥ 7) et le résidu, reflètent les dynamiques lentes et persistantes. Ceux sont les composantes structurelles du volumes. On confirme ainsi que la distinction entre fluctuation transitoires et composante persistante est centrale dans la littérature (Phillips et al., 2015 ; Atsiwo, 2025).

Table 6: Fonctions de modes empiriques (IMFs)

IMF_class	mean	min	max	Economic interpretation
IMF 1–2	3.5	2.2	5.0	Bruit, microstructure du marché
IMF 3–4	16.8	9.9	25.1	Cycles hebdomadaires de marché
IMF 5–6	89.7	49.6	141.6	Cycles mensuels et réallocations progressives
IMF ≥ 7	552.8	254.0	1030.0	Dynamique lente et structurelle du volume




Figure 8: Décomposition EMD du volume logarithmique de MSFT




Figure 9: Décomposition EMD du volume logarithmique de Tesla




Figure 10: Décomposition EMD du volume logarithmique de TSLA

4.2.2 La hiérarchie énergétique

L'énergie de chaque **IFMs** est mesuré par sa contribution quadratique au signal total(**E_i**) pour quantifier les échelles temporelles. Les composantes dominantes sont identifiées par la part de l'énergie relative, et l'information résiduel non expliqué évaluée par l'erreur énergétique cumulée.

$$E_i = \sum_t \text{IMF}_i(t)^2.$$

$$e_i = \frac{\left\| x(t) - r(t) - \sum_{j \leq i} \text{IMF}_j(t) \right\|^2}{\left\| x(t) - r(t) \right\|^2}.$$

La hiérarchie énergétique est stable entre les trois actifs (**voir tableau 7 ci-après**). l'énergie est très concentré dans les IFMs de bases fréquence pour les séries en log-niveau. C'est la dominance des dynamiques de long terme dans l'évolution des volumes. A l'inverse, pour les variations logarithmiques, les fluctuations de court terme dominant, l'essentiel de l'énergie est porté par les IFMs de rang faible.

Table 7: Part d'énergie et erreur cumulée des IFMs

Variable	Signal	IMF	EnergyShare	CumEnergyError_ei
Volume MSFT	logS	1	0.0001	1.0012
Volume MSFT	logS	2	0.0001	1.0015
Volume MSFT	logS	3	0.0001	1.0015
Volume MSFT	logS	4	0.0000	1.0015
Volume MSFT	logS	5	0.0000	1.0009
Volume MSFT	logS	6	0.0000	1.0024
Volume MSFT	logS	7	0.0000	1.0024
Volume MSFT	logS	8	0.0000	1.0000
Volume MSFT	logS	9	0.9996	0.0000
Volume MSFT	dS_over_S	1	0.7228	0.3010
Volume MSFT	dS_over_S	2	0.1817	0.1093
Volume MSFT	dS_over_S	3	0.0733	0.0239
Volume MSFT	dS_over_S	4	0.0142	0.0071
Volume MSFT	dS_over_S	5	0.0026	0.0042
Volume MSFT	dS_over_S	6	0.0011	0.0030
Volume MSFT	dS_over_S	7	0.0022	0.0025
Volume MSFT	dS_over_S	8	0.0013	0.0009
Volume MSFT	dS_over_S	9	0.0008	0.0000
Volume TSLA	logS	1	0.0001	1.0002

Variable	Signal	IMF	EnergyShare	CumEnergyError_ei
Volume TSLA	logS	2	0.0001	1.0001
Volume TSLA	logS	3	0.0000	1.0003
Volume TSLA	logS	4	0.0000	1.0008
Volume TSLA	logS	5	0.0000	1.0005
Volume TSLA	logS	6	0.0001	1.0018
Volume TSLA	logS	7	0.0001	1.0036
Volume TSLA	logS	8	0.9997	0.0000
Volume TSLA	dS_over_S	1	0.7557	0.2683
Volume TSLA	dS_over_S	2	0.1555	0.0973
Volume TSLA	dS_over_S	3	0.0587	0.0340
Volume TSLA	dS_over_S	4	0.0169	0.0146
Volume TSLA	dS_over_S	5	0.0079	0.0069
Volume TSLA	dS_over_S	6	0.0031	0.0027
Volume TSLA	dS_over_S	7	0.0015	0.0009
Volume TSLA	dS_over_S	8	0.0003	0.0004
Volume TSLA	dS_over_S	9	0.0004	0.0000
Volume NASDAQ	logS	1	0.0000	1.0000
Volume NASDAQ	logS	2	0.0000	0.9997
Volume NASDAQ	logS	3	0.0000	0.9996
Volume NASDAQ	logS	4	0.0000	0.9999
Volume NASDAQ	logS	5	0.0000	1.0001
Volume NASDAQ	logS	6	0.0000	1.0002
Volume NASDAQ	logS	7	0.0000	1.0002
Volume NASDAQ	logS	8	0.9999	0.0000
Volume NASDAQ	dS_over_S	1	0.6328	0.4311
Volume NASDAQ	dS_over_S	2	0.2320	0.1691
Volume NASDAQ	dS_over_S	3	0.1072	0.0372
Volume NASDAQ	dS_over_S	4	0.0214	0.0095
Volume NASDAQ	dS_over_S	5	0.0048	0.0031
Volume NASDAQ	dS_over_S	6	0.0011	0.0011
Volume NASDAQ	dS_over_S	7	0.0005	0.0004

Variable	Signal	IMF	EnergyShare	CumEnergyError_ei
Volume NASDAQ	dS_over_S	8	0.0002	0.0001
Volume NASDAQ	dS_over_S	9	0.0001	0.0000

4.2.3 Régimes temporels : dominance des dynamiques de court terme

Les demi-périodes moyennes provenant des extrêmes locaux permettent de lier chaque IFM (rang faible, intermédiaire et rang élevé) regroupé en régime de court terme, moyen et long terme à une échelle temporelle bien précise. Les résultats présentés dans le tableau (8) ci-après, montrent une domination écrasante du court terme, soit **97%** de l'énergie des variations des volumes est concentrée dans les composantes rapides pour l'ensemble des trois actions américaines. Les régimes de moyen et long terme ne contribuent que faiblement. La forte turbulence de court terme (Tableau 9) coexistent avec une stabilité relative des dynamiques lentes (Awartani, 2025)

Table 8: Répartition énergétique par régime temporel

Variable	Regime	EnergyShare
Volume MSFT	Court terme	0.9778
Volume MSFT	Long terme	0.0054
Volume MSFT	Moyen terme	0.0168
Volume NASDAQ	Court terme	0.9719
Volume NASDAQ	Long terme	0.0019
Volume NASDAQ	Moyen terme	0.0262
Volume TSLA	Court terme	0.9699
Volume TSLA	Long terme	0.0053
Volume TSLA	Moyen terme	0.0248

Table 9: Résumé statistique des régimes temporels des IMFs

Variable	Régime	Demi-période moyenne	Nombre de cycles
Volume MSFT	Court terme	3.24	653.00
Volume MSFT	Moyen terme	13.95	153.50
Volume MSFT	Long terme	207.26	18.12
Volume TSLA	Court terme	3.38	634.25
Volume TSLA	Moyen terme	11.36	174.00
Volume TSLA	Long terme	240.99	22.50
Volume NASDAQ	Court terme	3.24	645.50
Volume NASDAQ	Moyen terme	13.87	158.50
Volume NASDAQ	Long terme	319.70	17.50

Note. Les régimes de court terme présentent des demi-périodes d'environ trois jours et un très grand

nombre de cycles, les régimes intermédiaires correspondent à des cycles de l'ordre de deux semaines, et les dynamiques long se caractérisent par une demi-période très étendues mais un nombre réduit de cycles.

4.2.4 La Robustesse de la décomposition

Quasi-orthogonalité des fonctions de modes empiriques La quasi-orthogonalité des modes empirique est utilisée pour évaluer la robustesse de la décomposition EMD. Le coefficient pour chaque paire d'IMFs (i, j) est définie par :

$$c_{ij} = \frac{|\langle f_i, f_j \rangle|}{\|f_i\| \|f_j\|}$$

Pour l'ensemble des actifs, on observe sur les matrices de quasi-orthogonalité (figure 11) des fortes diagonales et des termes hors diagonales largement faibles. Les moyens hors diagonales (**Tableau 10**) sont proche de **0.05** et les valeurs maximales inférieur à **0.45**. Cette séparation fréquentielle est satisfaisante dans l'ensemble.

Table 10: Résumé numérique de la quasi-orthogonalité des IMFs

Variable	Signal	Mean off-diagonal	Max off-diagonal
Volume MSFT	logS	0.0529	0.4242
Volume MSFT	dS_over_S	0.0479	0.3817
Volume TSLA	logS	0.0430	0.1611
Volume TSLA	dS_over_S	0.0454	0.4176
Volume NASDAQ	logS	0.0535	0.2231
Volume NASDAQ	dS_over_S	0.0540	0.2512




Figure 11: Quasi-orthogonalité des IMFs f_i

4.2.5 Avant et après 2022 : réorganisation des dynamiques

L'année 2022 représente un point de rupture déterminant pour les marchés financiers. Elle est identifiée comme la période correspondant à une phase de transition entre expansion spéculative et réallocation des dynamiques de marché (Maghyereh, Awartani, 2025; Basele, Phillips, Shi, 2025)

Avant 2022. Pour l'ensemble des actifs, les composantes de court terme dominant largement la dynamique des volumes, environ 98% de l'énergie totale est concentrée dans les fluctuations rapides (Tableau 11). Les régimes de moyen terme conservent un rôle secondaire mais non négligeable, et ceux du long terme reste très marginale. Du côté des prix, les trajectoires de valorisation sont différentes et antérieurs à la synchronisation observée lors du boom de l'IA. La hiérarchie énergétique est plus hétérogène, principalement sont gouvernés par les dynamiques intermédiaires, Microsoft et le Nasdaq. Tesla présentait déjà une dominance de long terme.

Après 2022. La structure énergétique associée au volume se polarise vers le court terme. La composante structurelle de long terme ne change pas, les ajustements microstructurelles s'intensifient et les horizons temporelles se compressent. C'est comme si le **choc de 2022** agit comme amplificateur des dynamiques transactionnelles plutôt que comme facteur de changement profonde du volume. En revanche, s'agissant la dynamique des prix, la quasi-totalité de l'énergie se concentre sur le long terme pour l'ensemble des actifs, c'est une rupture nette (Tableau 12 et 12). Il n'y a presque pas de cycles intermédiaires, c'est ce que (Atsiwo, 2025) appelle les phases de bulles spéculatives prolongées et de réévaluation lente.

Table 11: Variations énergétique avant et après 2022

Variable	Période	Court	Moyen	Long
Volume MSFT	Avant 2022	0.9743	0.0250	0.0007
Volume MSFT	Après 2022	0.9798	0.0165	0.0037
Volume TSLA	Avant 2022	0.9606	0.0312	0.0082
Volume TSLA	Après 2022	0.9703	0.0256	0.0041
Volume NASDAQ	Avant 2022	0.9779	0.0217	0.0004
Volume NASDAQ	Après 2022	0.9743	0.0241	0.0016

Table 12: Répartition énergétique des log-prix avant et après 2022

Asset	Période	Court	Moyen	Long
MSFT	Avant 2022	0.000012	0.999988	0.000000
MSFT	Après 2022	0.000014	0.000059	0.999927
TSLA	Avant 2022	0.000059	0.000718	0.999223
TSLA	Après 2022	0.000089	0.000438	0.999473
NASDAQ	Avant 2022	0.000005	0.999995	0.000000
NASDAQ	Après 2022	0.000004	0.000041	0.999955




Figure 12: L'évolution des prix avant et après 2022

4.3 Discussion

Nous avons montré une dissociation nette entre dynamiques de volumes et celles des prix à partir de **2022**. D'un coté, c'est le court terme qui domine l'activité transactionnelle devenant plus fragmenté; de l'autre coté, les prix s'ancrent d'avantages dans des dynamiques de long termes. Ce que montrent (**Basele, Phillips et Shi, 2025**), les fluctuations de court terme peuvent augmenter sans détériorer immédiatement les tendances de long terme des prix. L'approche **EMD** nous apporte ainsi

un éclairage complémentaire des bulles spéculatives détectés. On a le choc de **2022** qui n'altère pas l'architecture structurelle des volumes, il reconfigure plutôt l'interaction entre échelles temporelles. La récente dynamique spéculative repose moins sur une expansion généralisée de l'activité que sur une réallocation asymétrique des horizons temporelles.

5 Analyse ondulatoire des mouvements de prix

Le but principal de cette étude est d'étudier l'évolution des prix de **Microsoft**, **Tesla** et du **Nasdaq Composite** au cours du temps en se concentrant sur la rupture possible du régime de marché vers **2022**. C'est une ère de transition avec **l'explosion de l'IA, la revalorisation massive des actifs technologiques et le changement des attentes des investisseurs**. Pour saisir ces évolutions, il faut un cadre méthodologique qui puisse rendre compte à la fois des évolutions de court, moyen et long terme. L'analyse par ondelettes offre un tel cadre. Contrairement aux méthodes spectrales classiques, qui utilisent des décompositions globales en fréquence, les ondelettes offrent une lecture conjointe temps-échelles. Cette propriété est bien adaptée à l'analyse des séries financières, fortement non stationnaires, avec des changements de régime et des périodes d'instabilité localisées dans le temps. Les bases théoriques de l'analyse en ondelettes sont posées par **Grossmann** et **Morlet** qui introduisent la transformée continue en ondelettes comme outil d'analyse temps-fréquence et par **Daubechies** qui définit des bases **orthogonales à support compact**, permettant une implémentation numérique stable. Dans sa forme discrète, **la décomposition multirésolution de Mallat** permet d'écrire une série temporelle comme la somme d'une composante de tendance de long terme et de composantes de détail associées à des horizons de plus en plus courts. Cette hiérarchie permet une interprétation naturelle des mouvements financiers sur différents horizons de temps.

$$W_x(a, b) = \frac{1}{\sqrt{a}} \int_{-\infty}^{+\infty} x(t) \psi\left(\frac{t-b}{a}\right) dt,$$

$$x(t) = A_J(t) + \sum_{j=1}^J D_j(t),$$

où $\psi(t)$ est l'ondelette mère, $a > 0$ est l'échelle (dilatation) et b est la translation temporelle.

En finance, l'analyse ondulatoire a été utilisée pour analyser la volatilité, la persistance des cycles et les comportements spéculatifs. **Ramsey** met en évidence par exemple que les ondelettes révèlent des cycles multi-échelles non visibles dans les représentations classiques, **Gençay et al.** montrent que les marchés financiers ont des propriétés d'échelle persistantes, avec des dynamiques différentes selon l'horizon d'analyse. Plus récemment, ces approches multi-échelles ont été utilisées pour étudier les bulles, les exubérances et les changements de régime.

Dans le cas particulier des **marchés technologiques récents**, cette lecture multi-horizons est indispensable. La littérature récente sur les bulles IA montre des dynamiques hétérogènes selon l'horizon temporel : des **phases d'explosivité** rapide identifiées par des **tests de type PSY ou GSADF**, des dynamiques plus persistantes associées à des bulles rationnelles, et des changements progressifs de structure mis en évidence par des approches de durée ou de mémoire longue (**Dettoni, Gil-Alana & Bahamondes, 2025 ; Atsiwo, 2025**). L'analyse par ondelettes vient compléter ces approches en visualisant la façon dont l'énergie des mouvements de prix se répartit entre le court, le moyen et le long terme au cours du temps.

Dans cette recherche, l'analyse en ondelette est employée pour étudier le **comportement des prix avant et après 2022**, en détectant les éventuelles recompositions des dynamiques multi-échelles liées à cette période de transition. Il ne s'agit pas seulement d'identifier des périodes de volatilité ou de rupture ponctuelle, mais de décrire **comment la structure temporelle des variations de prix a changé entre les deux sous-périodes**. Cette démarche permet alors d'associer les variations constatées des prix à un changement plus fondamental de régime de marché, lié aux transformations technologiques et financières récentes. Cette partie situe donc le cadre théorique et méthodologique de l'analyse ondulatoire. Les sections suivantes présenteront d'abord une étude préliminaire des séries de prix, puis les résultats empiriques de la décomposition multi-échelles et leur interprétation économique.

5.1 Analyse préliminaire

L'analyse ondelette est basée sur les mêmes séries financières quotidiennes **Microsoft, Tesla et l'indice Nasdaq composite** représentatifs du secteur technologique et du marché américain. Les prix ajustés de clôtures et les volumes échangés sont conjointement exploités pour chaque actif afin de capturer la dynamique des valorisations d'une part, et d'autre part, l'intensité de l'activité de marché. Les données comportent 1 269 observations journalières et couvrent la période du 5 janvier au 23 janvier 2026. Cela garantit la comparabilité des dynamiques observées permettant d'analyser **avant et après 2022**, l'évolution des prix des différents actifs.

1. Traitement des volumes :

Nous observons une distribution asymétrique des volumes, et une variance instable. C'est la raison pour la quelle une transformation logarithmique est appliquée afin de limiter l'influence des valeurs extrêmes. Pour mesurer les variations relatives de l'activité du marché, la dynamique du volume a été ensuite approximée.

$$\log S_t = \log(1 + S_t),$$

, avec S_t le volume inchangé à une date t .

$$\frac{dS}{S} \approx \frac{S_t - S_{t-1}}{S_{t-1}},$$

1. Traitement des prix :

Les prix ajustés sont transformés en logarithmes puis différenciés pour obtenir une approximation des rendements continus :

$$\log P_t = \log(\text{prix ajusté}_t),$$

$$\frac{dP}{P} \approx \log P_t - \log P_{t-1}$$

L'objectif étant d'éliminer les effets de niveau et refléter les fluctuations relatives des prix.

La figure 13 représente l'évolution temporelle des variations logarithmiques des prix des trois actifs. Globalement, on observe que les rendements sont centrés autour de zéro, tout fois, caractérisés par une volatilité variable dans le temps.




Figure 13: Évolution de la série

Note. Tesla se distingue des autres par des fluctuations nettement plus amples, le Nasdaq et Microsoft présentent des profils plus modérés. Toutefois, il y a des épisodes de turbulence communs. Des périodes d'intensifications des variations sont plus marquées autour de 2021-2022, suivie de phases de volatilité intermittente après 2022. Dès lors, on peut suggérer l'existence des dynamiques de dépendantes de l'horizon temporelle.

5.2 Résultat

5.2.1 Décomposition ondelette des log-prix

La décomposition ondelette des log prix distingue visiblement les composantes de long terme associées aux tendances structurelles des fluctuations de haute fréquence, ce qui est conforme à l'algorithme de décomposition multi-résolution de Mallat. Chaque série de log de prix est décomposée en une composante d'approximation $\mathbf{S_J}$ et en une suite de composante de détails $\mathbf{D_J}$, correspondant respectivement l'évolution lente du niveau des prix et les horizons temporelles de plus en plus courts.

Les figures 14, 15 et 16 illustrent pour chaque actif, les composantes de détails. Aux échelles les plus élevées ($\mathbf{D_1}$ à $\mathbf{D_3}$), les fluctuations rapides, peu persistantes et fortement irréguliers, dominent les séries. Elles caractérisent les ajustements de court termes et de réactions immédiates aux chocs dites informationnels. Centré au tour de zéro, ces composantes symbolisent le bruit de marché et la volatilité instantanée. Les échelles intermédiaires ($\mathbf{D_4}$ à $\mathbf{D_5}$) illustrent les oscillations plus persistantes et plus régulières. Ces dynamiques de moyen terme représente le niveau essentiel de transition permettant la propagation des mouvements de court terme vers les tendances de long horizon.

Enfin, les composantes de plus basse fréquence ($\mathbf{D_6}$ à $\mathbf{D_7}$) associées à des **cycles de long terme et à des phases prolongées d'expansion ou encore de correction des prix**, montrent des mouvements lents et cohérents. Elles traduisent les régimes macro financiers sous-jacents et contribuent directement à la formation de la tendance globale $\mathbf{S_J}$.

Globalement, l'organisation hiérarchique des dynamiques des prix reste similaire au trois actifs, en particulier pour **Tesla**. Cette décomposition constitue dans les sections suivantes, le socle empirique de l'analyse comparative pour examiner les changements de régimes autour de **2022**.

$\Delta P/P$ (MSFT) — D_j (détails)




Figure 14: Composantes fréquentielles du Microsoft



Figure 15: Composantes fréquentielles de TSLA

$\Delta P/P$ (NASDAQ) — D_j (détails)



Figure 16: Composantes fréquentielles du Nasdaq

5.2.2 Rendements et distribution énergétique

La décomposition ondelette appliquée aux rendements logarithmiques $\Delta P/P$ montre une organisation très différentes de celle des log - prix. Alors que ces derniers sont marqués par les fréquences basses, l'essentiel des énergies des rendements sont concentrés dans les hautes fréquences. Il y'a ici une prépondérance des fluctuations rapides et des chocs transitoires.

Le tableau 13 montre, entre **75%** et **80%** de l'énergie totale des rendements est concentrée dans le court terme pour les trois actifs, domination marquée particulièrement pour **Microsoft** et le **Nasdaq**. **Tesla** affiche une contribution relativement plus importante des échelles intermédiaires et de long terme, c'est la dynamique plus sensible et plus persistante aux cycles spéculatifs.

La figure 17 confirme ce résultat en illustrant la contribution cumulative des échelles ondelettes à la variance des rendements. L'erreur énergétique cumulée décroît rapidement, les échelles de plus basse fréquence n'apportent qu'une contribution marginale, ce qui fait que l'essentielle de la variance est expliquée par les premiers composantes ($\mathbf{D}_1$ à $\mathbf{D}_3$). Il y a alors une opposition structurelle entre rendement et prix, d'ailleurs, cela corrobore la littérature financière. En effet, les prix évoluent selon les tendances lentes et agrègent progressivement l'information, les rendement, par contre, illustre l'activité spéculative, le bruit informationnel à haute fréquence et l'incertitude. A travers cette décomposition ondelette, nous quantifions ici cette distinction fondamentale.

Table 13: Répartition énergétique des rendements

Asset	Court terme	Moyen terme	Long terme
MSFT	0.789	0.170	0.041
TSLA	0.758	0.174	0.068
NASDAQ	0.768	0.192	0.040




Figure 17: Contribution cumulative des échelles ondelettes à la variance des rendements

5.2.3 Orthogonalité des composantes ondelettes

La validité de la méthode ondelette repose en partie sur la capacité à isoler les dynamiques spécifiques à chaque horizon temporel. La figure 18 présente les matrices de corrélations entre composante ondelettes et des rendements, elle montre pour les trois actifs, une structure quasi-diagonale. Sur la diagonale et proches de zéro hors diagonale, on a des corrélations élevées, confirmant ainsi la quasi orthogonalité des composantes D_j . Chaque bande fréquentielle reflète sans redondance significative, une information spécifique. Cette propriété permet d'assurer que les dynamiques de court, moyen et long terme correspondent bien à des mécanismes distincts, ce qui garantit une interprétation cohérente des résultats énergétiques et temporelles précédemment présentés.




Figure 18: Matrice de corrélation des composantes ondelettes des rendements D_j

Scalogrammes CWT et structure temps-fréquence :




Figure 19: Structure temps-fréquence des rendements (scalogramme ondelette)

L'analyse (**DWT**) est complétée par les scalogrammes de la transformé continue en ondelettes (**CWT**) en offrant une représentation conjointe du temps et des échelles. La figure 19 illustre une structuration claire des concentrations énergétiques des rendements.

Les échelles longues symbolisent une énergie diffuse et relativement stable. Cela reflète les mouvement lents et persistant. Tandis que, les échelles courtes concentrent des pics énergétiques localisés, typique caractéristiques de chocs transitoires et d'épisodes de forte activité informationnelle. L'élément centrale que l'on trouve autour de **la phase postérieure à 2022**, est l'intensification des concentrations énergétiques.

Cette structure **temps - fréquence** révèle un changement progressive du régime dynamique. Les fluctuations rapides interagissent davantage avec les composantes de plus long horizon, et gagnent en intensité. Le caractère non instantané, mais graduel, des ajustements de marché observés autour de 2022 est confirmé par les scalogrammes.

5.2.4 Comparaison des rendements avant et après 2022

L'objectif étant d'identifier un éventuel changement de régime dans un contexte macro-financier profondément transformé. Pour ce faire, l'analyse ondelette des rendements est conduite séparément sur la période **pré - 2022** et **post - 2022**.

Avant 2022, le court terme domine fortement la structure énergétique des rendements, soit **80%** de l'énergie est concentré dans les hautes fréquences pour **Microsoft** et le **Nasdaq**, et près de **79%** pour **Tesla**. Nous avons un régime de marché hautement réactif et principalement piloté par des chocs informationnels de court terme et une volatilité instantanée élevée.

Après 2022, l'évolution énergétique est plutôt nuancé. On a d'un coté, la part du court terme qui diminue légèrement, et d'un autre coté, les composantes de moyen terme qui gagnent en importance pour les trois actifs. Particulièrement, **Tesla** se distingue par une augmentation plus marquée de la composante de long terme.

La volatilité demeure dominée par des fluctuations rapides, par contre la période **post - 2022** se caractérise par une structuration plus visibles des rendements et une mémoire temporelle renforcée. Les résultats suivent la logique des analyses récentes, notamment ceux de (**Basele, Phillips & Shi, 2025 ; Maghyereh & Awartani, 2025**) sur les bulles technologiques et l'essor de l'intelligence artificielle mettant en accent les dynamiques spéculatives plus persistantes après 2022.

Table 14: Répartition énergétique des rendements avant et après 2022

Asset	Période	Court terme	Moyen terme	Long terme
MSFT	Avant 2022	0.812	0.144	0.044
MSFT	Après 2022	0.785	0.169	0.046
TSLA	Avant 2022	0.789	0.178	0.033
TSLA	Après 2022	0.771	0.153	0.075
NASDAQ	Avant 2022	0.811	0.145	0.044
NASDAQ	Après 2022	0.780	0.174	0.046

Répartition énergétique des rendements avant / après 2022




Figure 20: L'évolution des prix avant et après 2022

Ruptures structurelles :

Afin de compléter notre analyse ondelette, une détection de rupture non paramétrique fondée sur l'algorithme de segmentation binaire (**BingSeg**) est appliquée aux séries de rendements. Les résultats s'inscrivent dans la logique des travaux sur les bulles rationnelles et spéculatives (**Dettoni, Gil-Alana & Bahamondes, 2025 ; Atsiwo, 2025**), confirmant que les transformations **post 2022** relèvent moins d'une rupture brutale que d'une reconfiguration progressive du régime de marché. Dans notre analyse, les ruptures identifiées se situent autour de la période **fin 2022** et **début 2023** pour **Tesla** et le **Nasdaq**, Microsoft présente des ruptures tardives.(voir tableaux 15). La figure 19 illustre des ruptures ne correspondant pas à un changement instantané, mais à une phase de transition prolongée. il y'a un ajustement des anticipations de marché. Le tableau 15 montre une transformation structurelle du processus de formation des prix pendant la période **post 2022**. Il y a une plus forte volatilité et une sensibilité renforcée aux chocs d'information et par conséquent une réorganisation des dynamiques multi-échelles.




Figure 21: Évidence de rupture structurelle dans la dynamique des rendements)

Table 15: Dates de ruptures structurelles détectées

Asset	Rupture 1	Rupture 2
MSFT	2025-04-08 00:00:00	2025-10-28 00:00:00
TSLA	2023-01-05 00:00:00	2023-01-27 00:00:00
NASDAQ	2022-12-13 00:00:00	2022-12-28 00:00:00

5.3 Discussion

Cette étude de l'analyse ondulatoire autour de 2022, révèle une reconfiguration des dynamiques des prix et des rendements progressive, plutôt qu'une brutale rupture. Celle-ci s'inscrit dans les débats récents questionnant la nature des bulles technologiques et les changements de régimes spéculatif liés à l'avènement de l'intelligence artificielle.

Organisation multi-échelle et dynamique spéculative :

Les résultats illustrent que les composantes de basse fréquence traduisant les tendances de long terme et relativement stable sont dominées par les log-prix. Tandis que l'essentiel des énergies des rendements sont concentrées dans les hautes fréquences. C'est une dissociation structurelle qui confirme l'idée que les marchés financiers agrègent de manière progressive au niveau des prix l'information, mais réagissent instantanément et plus volatile aux chocs informationnels via les rendements.

L'hierarchie des échelles viennent rejoindre ici les conclusions de Ramsey(2002) et de Gençay et al. (2001). Toute fois, dans le contexte des actifs liés à l'IA, elle prend une dimension spécifique, car la forte concentration d'énergie à court terme dans les rendements reflète un environnement spéculatif prononcé par des anticipations parfois révisées fréquemment, et aussi une attention accrue des investisseurs, ainsi qu'une forte sensibilité aux nouvelles macroéconomiques et technologiques.

Avant 2022 : régime dominé par les chocs de court terme :

Les hautes fréquences pour l'ensemble des actifs dominent nettement la structure énergétique. On a une configuration similaire à un régime de marché qui est fortement réactif, autrement, la volatilité est générée principalement par des chocs transitoires et des ajustements automatiques des anticipations.

Le résultat obtenu étant parfaitement cohérent avec la phase d'expansion technologique post-2020, une période caractérisée par une liquidité abondante et des politiques monétaires accommodantes. l'activité spéculative du court terme traduit principalement les anticipations de croissance liées aux technologies numériques et, en particulier à l'IA. Il n'y a pas structuration très marquée des dynamiques de moyen et long terme.

Après 2022 : reconfiguration du régime et montée de la persistance :

La redistribution de l'énergie vers les échelles intermédiaires est progressive sauf dans le cas de Tesla, l'énergie est redistribuée vers les basses fréquences. On a donc un régime de marché qui est marqué par la persistance des mouvements de prix et la restructuration des rendements plus nette.

Cette reconfiguration corrobore les conclusions de **Basele, Phillips et Shi (2025)**. Ils affirment que le boom récent de l'IA est accompagné de dynamiques spéculatives durables et détectables par des méthodes de types **PSY/GSDAF**. Contrairement aux épisodes purement euphoriques, les anticipations ancrées d'avantages dans des récits technologiques structurants caractérisent la période **post-2022**, traduisant ainsi une mémoire temporelle longue.

Également, ces analyses restent compatibles avec ceux de **Maghyreh et Awartani (2025)**. Ils détectent les bulles spéculatives dans le secteur de l'IA sur la période **2020-2022** et postérieur, en mettant l'accent sur le rôle des conditions financières, de la liquidité et de l'incertitude. Ainsi, le passage d'une **spéculation opportuniste à une spéculation plus persistante et intégrée aux anticipations de long horizons, peut traduire une augmentation relative de l'énergie de long terme.**

Ruptures structurelles et ajustement progressif des anticipations :

La transition autour de 2022 ne correspond pas à un choc unique, mais à une phase étalée d'ajustement dans le temps, ce que confirme la détection de rupture structurelle. Les marchés ne réévaluent pas instantanément la valeur fondamentale des actifs technologiques, mais par ajustement successifs, ce qui rend intéressante la lecture du point de vue économique. Cela s'inscrit dans l'analyse de **Dettoni, Gil-Alana et Bahamondes (2025)**, en affirmant qu'il peut avoir une coexistence entre les bulles rationnelles et les processus de correction graduels caractérisé par une mémoire longue. Les ruptures détectées dans ce cadre traduisent ainsi moins l'éclatement d'une bulle qu'une recomposition progressive du régime spéculatif

Enfin, nous apportons un éclairage complémentaire aux récentes approches basées sur la détection des bulles d'une part, et d'autre part sur les méthodes automatiques d'apprentissages. L'approche ondelette ne cherche pas à diagnostiquer explicitement les épisodes de bulle, mais à spécifier la structure temporelle sous-jacente des dynamiques de marché, contrairement à Atsiwo (2025) qui combine tests PSY/GSDAF. Cette analyse permet de mieux appréhender les régimes spéculatifs se transformant dans le temps, notamment la réorganisation des horizons temporels après 2022. C'est un outil complémentaire pour analyser en amont ou en aval des méthodes de détections directives des bulles technologiques.

6 Détection des bulles spéculatives

L'objectif de cette section étant d'identifier et de dater les épisodes de bulles spéculatives en s'appuyant sur les tests récurrents de racine explosive présenté par **Phillips, Shi et Yu (2015)**. C'est la référence empirique aujourd'hui pour la détection des bulles financières liés à l'intelligence artificielle.

6.1 Méthodologie : tests GSADF et BSADF

Principalement, cette détection s'appuie sur deux statistiques complémentaires. La statistique **GSADF** (**G**eneralized **S**upremum **A**DF) permet de vérifier l'existence globale de comportements explosifs sur l'ensemble de la période étudiée. S'agissant de la statistique **BSADF** (**B**ackward **S**upremum **A**DF), permet spécifiquement de dater les épisodes de bulles en détectant les périodes durant lesquelles la statistique dépasse le seuil critique. Le seuil critique obtenu par bootstrap résulte de l'hypothèse nulle de marche aléatoire, fixant une fenêtre de taille minimale à $r_0 = 0,1T$. On dira qu'une période est identifiée comme bulle dès lors que la statistique BSADF dépasse le seuil critique au niveau de 95%.

6.2 Résultats empiriques

Les résultats montrent une forte hétérogénéité marquée entre les actifs. La statistique **GSADF** associée à **TSLA** excède nettement son seuil critique, on a un comportement explosif significatif sur la période étudiée (**2021-2026**). Nous observons deux épisodes majeurs de bulle dans les graphiques **BSADF** (Voir figure 22), dont l'une autour de **2021-2022**, et l'autre au début de l'année **2023**. Ceux sont des phases qui s'apparentent à des envolées rapides des prix et suivies d'ajustement ou de correction abruptes, typiques des dynamiques de bulle rationnelles. S'agissant du **Nasdaq**, la statistique **GSADF** demeure inférieure au seuil critique, il n'y a pas de bulle globale persistante. Par contre, l'analyse **BSADF** révèle autre chose, on a des épisodes localisés de tension spéculative et de courte durée qui ne s'auto-entretiennent pas suffisamment pour décrire une bulle durable à l'échelle de l'indice. Quant au **MSFT**, on s'aperçoit que ni la statistique **GSADF**, ni celle du **BSADF** ne dépassent les seuils critiques. La dynamique des prix se révèle plus régulière, la trajectoire est soutenue principalement par les fondamentaux plutôt que par une dynamique spéculative auto-renforcée.

Table 16: GSADF bubble detection and BSADF dating results

Asset	GSADF	Critical_95	Exceedance	Bubble	Start	End	Duration
MSFT	0.884	1.739	-0.855	No	-	-	0
TSLA	2.965	1.894	1.071	Yes	2021-10-28	2022-12-28	9
NASDAQ	0.807	2.187	-1.380	No	-	-	0




Figure 22: Les potentiels bulles spéculatives de MSFT, NASDAQ et TSLA

6.3 Discussion

Les titres fortement exposés aux narratifs technologiques et à l’anticipation d’innovation disruptifs, à l’instar de **Tesla**, présente plus de bulle plutôt que sur les entreprises technologiques matures ou les indices agrégés. Cette hétérogénéité confirme les conclusions de **Maghyereh et Awartani (2025)** et de **Basele, Phillips et Shi (2025)**. Les bulles liées à l’IA sont concentrées sur certains titres, celles associées aux Nasdaq sont souvent synchronisées mais de durée limitée et sans nécessairement conduire à une explosion persistante de l’indice.

Pour compléter cette analyse, nous mobilisons ainsi dans la section suivante suivante, les méthodes de Machine Learning afin de déterminer si les variables d’attention des investisseurs, l’incertitude économiques et les conditions de liquidité possèdent un pouvoir prédictives sur les rendements journaliers. Autrement dit, examiner si les périodes identifiées comme spéculatives correspondent également à des régimes où l’information comportementale et macrofinancières sont partiellement exploitable.

7 Machine learning

L'objectif de cette section est d'étudier le pouvoir prédictif hors échantillon des variables de marché, d'incertitude et d'attention des investisseurs sur les rendements logarithmiques journaliers $r_t = \ln(p_t/p_{t-1})$ de TSLA, MSFT et NASDAQ, à l'aide des modèles de Random Forest. Cette étude est complémentaire à la section précédente (détection des bulles GSADF & BSADF) et s'inscrit aussi dans la même logique de Basele et al. (2024), Dettoni et al. (2023) et Atsiwo et al. (2022)

7.1 Prétraitement des données

Les rendements logarithmiques journaliers

$$r_t = \ln \left(\frac{p_t}{p_{t-1}} \right),$$

présentés dans la figure 23 montrent une forte volatilité, particulièrement marqué pour **TSLA**. **MSFT** et **NASDAQ** apparaissent plus stables.

La figure 24 représente la matrice de corrélation, elle met en évidence :

- une forte corrélation entre les rendements des actifs, on ici les effets de spillovers;
- des relations non linéaire entre rendements et variables macro financiers (**VIX**, matières premières (**GOLD**, **OIL**), **EPU**), principalement adaptée aux méthodes de Machine Learning non paramétrique.

Pour ce faire, les données sont scindées de manière strictement temporelle, **75% entraînement** et **25% test**, cela permet d'éviter toute fuite d'information (Hamou, Cours de Support, 2026)




Figure 23: Rendement logarithmique des actif




Figure 24: Matrice de corrélation

7.2 Résultats

Performance des modèles Le tableau 17 présente les performances des Random Forest et illustre les capacités prédictives significatives de l'échantillon test (**hors échantillon**), en particulier pour **TSLA** et **NASDAQ**.

- NASDAQ : la dynamique est plus régulière et prédictible, c'est la meilleure performance globale ($R^2_{\text{test}} \approx 0.65$).
- MSFT : la performance est solide mais plus modérée ($R^2_{\text{test}} \approx 0.42$).
- TSLA : présente le plus volatil des actifs, cependant le modèle conserve un pouvoir explicatif non négligeable ($R^2_{\text{test}} \approx 0.46$).

Le nuage de points global (41) et les graphiques de Prédiction & Réel(25) illustrent en moyenne une bonne capacité de suivi de la dynamique, malgré la sous-estimation des chocs extrêmes. Ce résultat est attendu pour les rendements journaliers.

Table 17: Résultats

Actif	RMSE_train	R2_train	RMSE_test	R2_test
MSFT	0.7228	0.8083	1.2291	0.4198
TSLA	2.2186	0.6368	3.0103	0.4606
NASDAQ	0.4830	0.8834	0.8455	0.6518

Table 18: prediction & Reel : les 20 premiers valeurs test

	Réel_MSFT	Préd_MSFT	Réel_TSLA	Préd_TSLA	Réel_NASDAQ	Préd_NASDAQ
2024-10-22 00:00:00	2.0632	0.1147	-0.4029	-0.2376	0.2142	1.3319
2024-10-23 00:00:00	-0.6830	-1.6388	-2.0018	-2.1725	-1.6449	-0.6333
2024-10-24 00:00:00	0.0306	0.6036	19.8187	6.1458	0.7568	0.5107
2024-10-25 00:00:00	0.8020	0.1252	3.2891	1.1188	0.5584	1.0933
2024-10-28 00:00:00	-0.3650	0.2072	-2.5128	0.7408	0.2620	-0.4857
2024-10-29 00:00:00	1.2486	0.8763	-1.1455	0.5430	0.7809	0.6545
2024-10-30 00:00:00	0.1342	-0.7788	-0.7620	-0.8510	-0.5617	0.2029
2024-10-31 00:00:00	-6.2437	-2.0505	-3.0353	-3.3243	-2.7944	-2.7633
2024-11-01 00:00:00	0.9844	0.9456	-0.3488	0.5192	0.7969	0.4989
2024-11-04 00:00:00	-0.4665	-0.2579	-2.4970	-0.8603	-0.3292	-0.6206
2024-11-05 00:00:00	0.7318	0.9660	3.4802	1.8139	1.4156	1.0901
2024-11-06 00:00:00	2.0971	2.2875	13.7595	5.1645	2.9091	1.8677
2024-11-07 00:00:00	1.2417	1.1335	2.8630	2.0846	1.4953	1.2399
2024-11-08 00:00:00	-0.6816	-0.1854	7.8697	2.0077	0.0898	0.3402
2024-11-11 00:00:00	-1.0779	-0.2402	8.5807	1.2019	0.0621	0.3125
2024-11-12 00:00:00	1.1938	-0.2251	-6.3427	-2.0251	-0.0900	0.3315
2024-11-13 00:00:00	0.5117	-0.3578	0.5313	-1.5709	-0.2632	0.3049
2024-11-14 00:00:00	0.3967	-0.5054	-5.9448	-1.3688	-0.6420	-0.4221
2024-11-15 00:00:00	-2.8248	-1.9284	3.0197	-5.6445	-2.2629	-0.8215
2024-11-18 00:00:00	0.1830	0.0837	5.4664	0.7010	0.5961	0.7891




Figure 25: Valeurs prédites & valeurs réelles des rendements







Figure 26: Nuage de point des rendements prédites et réels



(a)



(b)



(c)

Figure 27: Les résidus prédites

Importance des variables Le Tableau d'importance (19) ci-après montre un résultat central et robuste.

Table 19: Importance des variables

	MSFT	TSLA	NASDAQ
r_NASDAQ	0.8387	0.6756	0.0000
r_MSFT	0.0000	0.0528	0.7761
r_TSLA	0.0202	0.0000	0.1357
VOL_TSLA	0.0075	0.1354	0.0052
VOL_MSFT	0.0814	0.0213	0.0157
VIX	0.0071	0.0147	0.0343
WIKI_AI	0.0085	0.0216	0.0053
OIL	0.0057	0.0198	0.0085
VOL_NASDAQ	0.0116	0.0144	0.0066
EPU	0.0067	0.0204	0.0041
GOLD	0.0067	0.0158	0.0045
GT_StockMarket	0.0057	0.0081	0.0040

Note.

Les rendements croisés l'emportent nettement sur les explications des rendement propres. dominant largement l'explication des rendements propres. L'attention des investisseurs ((WIKI_AI, GT_StockMarket), l'incertitude (EPU) et l'indice de la peur (VIX) jouent un rôle secondaire, mais non négligeable. Quant aux volumes, leurs contributions sont d'avantage pour TSLA, cohérent avec sa forte sensibilité à la liquidité. Comme suggérée par la littérature récente sur les bulles technologiques, nos résultats confirment empiriquement l'existence de spillovers inter-actifs.

7.3 Discussion

Les rendements journaliers conservent une structure prédictible partielle, exploitable par des modèles non linéaires, contrairement à une vision strictement efficiente des marchés. Selon les actifs, la prédictibilité est hétérogène et s'atténue avec la volatilité intrinsèque (TSLA). La principale source d'information prédictive concerne les interactions entre actifs; les variables d'attention et d'incertitude ne suffisent pas seul à améliorer la performance. En conformité avec les tests GSADF et BSADF, les bulles ne sont pas uniquement des phénomènes de prix, mais aussi d'information et d'attention, car la phase de boom spéculatif s'accompagne d'une augmentation du pouvoir prédictif des variables comportementales.

8 Conclusion

Concrètement, ce travail à examiner la récente dynamique des marchés financiers à travers le prisme du boom de l'intelligence artificielle. Il combine des approches **économétriques, les ondelettes, décomposition EMD et les machines learning appliqués** aux actions de Microsoft, Tesla et à l'indice Nasdaq Composite sur la période **2021-2026**. L'analyse exploratoire et les test de stationnarité corroborent les faits stylisés traditionnels des rendements financières : non stationnarité des prix, les rendements stationnaires, hétéroscédasticité conditionnelle et clustering de volatilité. Les modèles **GARCHES** donnent une mesure parcimonieuse et robuste de la volatilité conditionnelle, indispensable pour présenter les phases d'instabilité des actifs.

Les Tests **GSADF/BSADF** de détection de bulles spéculatives illustrent une phase explosive hautement marquée sur **Tesla** sur la période de **2021-2022**, **Microsoft et le Nasdaq** apparaissent moins exposé à des dynamiques purement spéculatives.

La décomposition multi-échelle par **EMD** montre une organisation temporelle hautement stable entre les trois actifs. La volatilité est fortement dominée par les dynamiques de court terme, alors que restent structurellement plus stables les composantes de long terme. Principalement, les phases spéculatives s'expriment par une intensification rapides des fluctuations que plutôt par une rupture immédiate des tendances structurelles.

Le modèle de machine learning appliqué aux rendements présente un pouvoir explicatif restreint pour les approches linéaires mais non négligeable. Il capture partiellement l'impact des variables de marché telles que le **VIX, les volumes et les indicateurs de sentiment**. On souligne les limites prédictives à court terme des rendements et met en avant l'intérêt du machine learning comme utile supplémentaire d'analyse structurelle et de hiérarchisation des facteurs.

En sommes, le travail montre que le boom de l'intelligence artificielle à transformer la dynamique des marchés technologiques, renforçant les comportements spéculatifs et l'instabilité de court terme sans toute fois remettre en cause les fondamentaux de long terme. Il ouvre ainsi la voie à des prolongements intégrant des modèles non supervisés et des approches de détection de régimes pour mieux spécifier les transitions entre phases normales et spéculatives.

9 Références

- Atsiwo, A. (2025). A Three-Step Machine Learning Approach to Predict Market Bubbles with Financial News. *arXiv preprint* arXiv:2510.16636.
- Basele, A., Phillips, P. C. B., & Shi, S. (2025). Speculative Bubbles in the Recent AI Boom: Nasdaq and the Magnificent Seven. Working Paper.
- Campbell, J. Y., Lo, A. W., & MacKinlay, A. C. (1997). *The Econometrics of Financial Markets*. Princeton University Press.
- Chatzis, S. P., et al. (2018). Forecasting Stock Market Crisis Events Using Deep and Statistical Machine Learning Techniques. *Expert Systems with Applications*, 112, 353–371.
- Cont, R. (2001). Empirical properties of asset returns: Stylized facts and statistical issues. *Quantitative Finance*, 1(2), 223–236.
- Daubechies, I. (1992). *Ten Lectures on Wavelets*. SIAM.
- Dettoni, R., Gil-Alana, L. A., & Bahamondes, C. (2025). Analyzing Rational Speculative Bubbles in S&P 500 Index Sectors through Fractional Integration and Generalized Link-Based Additive Survival Models. *Finance Research Letters*, 85, 107759.
- Gençay, R., Selçuk, F., & Whitcher, B. (2001). *Scaling and Nonlinear Dynamics in Financial Markets*. Cambridge University Press.
- Grossmann, A., & Morlet, J. (1984). Decomposition of Hardy functions into square integrable wavelets of constant shape. *SIAM Journal on Mathematical Analysis*.
- Maghyreh, A., & Awartani, B. (2025). The Speculative Tech Bubbles of US Artificial Intelligence Sector. *Economics and Business Letters*.
- Mallat, S. (1989). A theory for multiresolution signal decomposition. *IEEE Transactions on Pattern Analysis and Machine Intelligence*.
- McQueen, G., & Thorley, S. (1994). Bubbles, Stock Returns, and Duration Dependence. *Journal of Financial and Quantitative Analysis*, 29(3), 379–401.
- Ozbugday, F. C., Yilanci, V., & Ozgur, O. (2021). Detecting Speculative Bubbles in Metal Prices: Evidence from GSADF Test and Machine Learning Approaches. *Resources Policy*, 74, 102306.
- Phillips, P. C. B., Shi, S., & Yu, J. (2015). Testing for Multiple Bubbles: Historical Episodes of Exuberance and Collapse in the S&P 500. *International Economic Review*, 56(4), 1043–1078.
- Ramsey, J. B. (2002). Wavelets in economics and finance. *Studies in Nonlinear Dynamics & Econometrics*.
- Yahoo Finance. Historical Data. Disponible sur <https://finance.yahoo.com>.

10 Annexes




Figure 28: Nuage de point EPU-NASDAQ




Figure 29: Nuage de point EPU-MSFT




Figure 30: Nuage de point EPU-TSLA




Figure 31: VIX-TSLA




Figure 32: Nuage de point GOLD-NASDQ




Figure 33: VIX-NASDAQ




Figure 34: Nuage de point GOLD-TSLA




Figure 35: VIX-TSLA




Figure 36: Importance variable-MSFT




Figure 37: Importance variable-TSLA




Figure 38: Importance variable-NASDAQ





Figure 39: Arbres de decisions-MSFT

```

graph TD
    Root["r_NASDAQ <= -0.567  
squared_error = 12.625  
samples = 599  
value = 0.109"]
    
    Root -- True --> Node1["r_NASDAQ <= -1.367  
squared_error = 10.515  
samples = 142  
value = -2.999"]
    Root -- False --> Node2["r_NASDAQ <= 0.414  
squared_error = 9.085  
samples = 457  
value = 1.133"]
    
    Node1 --> Node3["VOL_TSLA <= -0.258  
squared_error = 10.148  
samples = 45  
value = -5.119"]
    Node1 --> Node4["OT_StockMarket <= 1.45  
squared_error = 7.787  
samples = 97  
value = -2.055"]
    
    Node2 --> Node5["VOL_TSLA <= 2.291  
squared_error = 6.868  
samples = 263  
value = 0.059"]
    Node2 --> Node6["r_NASDAQ <= 1.537  
squared_error = 5.57  
samples = 194  
value = 2.5"]
    
    Node3 --> Node7["EPU <= -0.477  
squared_error = 4.553  
samples = 18  
value = -3.297"]
    Node3 --> Node8["r_MSFT <= -1.392  
squared_error = 10.39  
samples = 27  
value = -6.127"]
    
    Node4 --> Node9["VIX <= -0.27  
squared_error = 11.944  
samples = 9  
value = -1.85"]
    
    Node5 --> Node10["VOL_TSLA <= 1  
squared_error = 37.866  
samples = 5  
value = -0.13"]
    Node5 --> Node11["r_MSFT <= -0.221  
squared_error = 6.448  
samples = 162  
value = 1.991"]
    
    Node6 --> Node12["r_NASDAQ <= 2.296  
squared_error = 10.67  
samples = 32  
value = 5.327"]
    
    Node7 --> Node13["r_NASDAQ <= -1.755  
squared_error = 2.474  
samples = 12  
value = -2.52"]
    Node7 --> Node14["WIKI_AI <= -0.7  
squared_error = 1  
samples = 11  
value = -6.99"]
    
    Node8 --> Node15["VOL_NASDAQ <= -0.028  
squared_error = 6.084  
samples = 32  
value = -3.137"]
    Node8 --> Node16["VIX <= 0.025  
squared_error = 5.455  
samples = 60  
value = -1.109"]
    
    Node9 --> Node17["VOL_MSFT <= -0.015  
squared_error = 3.723  
samples = 199  
value = -0.17"]
    Node9 --> Node18["GOLD <= -0.4  
squared_error = 1  
samples = 5  
value = 1.20"]
    
    Node10 --> Node19["r_MSFT <= -0.07  
squared_error = 5.514  
samples = 157  
value = 1.544"]
    Node10 --> Node20["WIKI_AI <= 0.923  
squared_error = 7.07  
samples = 5  
value = 8.545"]
    
    Node11 --> Node21["VOL_MSFT <= 1  
squared_error = 32.71  
samples = 2  
value = 4.69"]
    Node11 --> Node22["VOL_MSFT <= 1  
squared_error = 32.71  
samples = 2  
value = 4.69"]
    
    Node13 --> L1["(-)"]
    Node13 --> L2["(-)"]
    Node14 --> L3["(-)"]
    Node14 --> L4["(-)"]
    Node15 --> L5["(-)"]
    Node15 --> L6["(-)"]
    Node16 --> L7["(-)"]
    Node16 --> L8["(-)"]
    Node17 --> L9["(-)"]
    Node17 --> L10["(-)"]
    Node18 --> L11["(-)"]
    Node18 --> L12["(-)"]
    Node19 --> L13["(-)"]
    Node19 --> L14["(-)"]
    Node20 --> L15["(-)"]
    Node20 --> L16["(-)"]
    Node21 --> L17["(-)"]
    Node21 --> L18["(-)"]
    Node22 --> L19["(-)"]
    Node22 --> L20["(-)"]
  
```

Arbre de décision extrait de la forêt – NASDAQ



Boubou DIANKA Master 2 Recherche EA 65